Propuesta Técnica: Data Lake

Modernización de la Arquitectura de Datos

Para: Director General, CaféNorte
De: Alejandro Victoria Peregrino
Fecha: 2 de noviembre de 2026

1. Arquitectura Propuesta en AWS

Para centralizar las operaciones de CaféNorte, proponemos una arquitectura **Data Lake Serverless y Event-Driven** en Amazon Web Services (AWS). Este diseño elimina costos fijos de servidores, garantiza la disponibilidad de la información, ofrece aislamiento de fallos y asegura pagar únicamente por los segundos de procesamiento y los datos almacenados.

Servicios Principales y Justificación Técnica

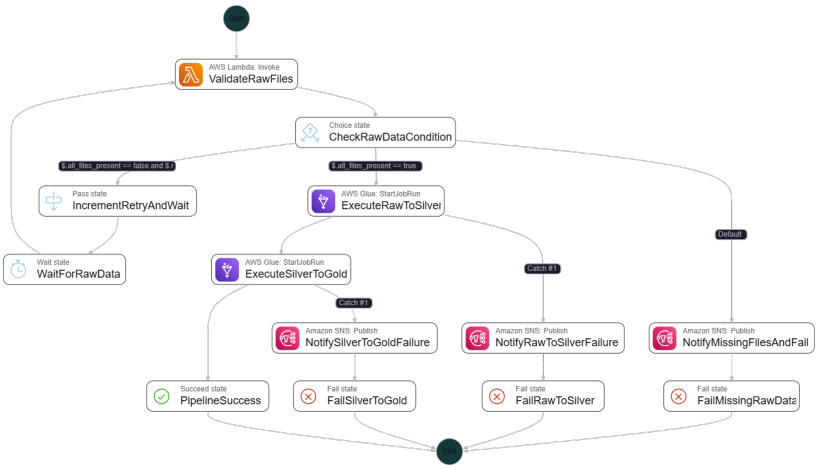
- **Amazon S3:** Repositorio central dividido en tres zonas lógicas: *Raw* (ingesta particionada por origen y fecha operativa), *Silver* (datos limpios, tipados y normalizado) y *Gold* (tablas unificadas listas para analítica).
- **AWS Lake Formation:** Gobierno de datos centralizada que opera sobre el almacenamiento en S3. Prepara el almacenamiento para aplicar controles de acceso por tabla, fila o columna.
- **Amazon EventBridge (Disparador de eventos):** Gestiona el inicio automático del pipeline diario (cierre nocturno propuesto a las 23:00 UTC).
- **AWS Lambda (Valida Precondiciones):** Microservicio que valida la presencia de los tres archivos (POS, Shopify, Inventario) previo al procesamiento.
- **AWS Step Functions (Orquestador):** Control y trazabilidad. Gestiona esperas pasivas, reintentos ante datos demorados, control de transformaciones y desvíos a estados de fallo.
- **AWS Glue Python Shell (Transformación ETL):** Ejecuta transformaciones optimizando tiempos de procesamiento.
- **Amazon SNS (Alertamiento Proactivo):** Administra notificaciones push que envía a correo automáticamente ante ausencia de archivos de entrada o caídas en la ejecución de los jobs de Glue.
- **AWS Glue Data Catalog y Amazon Athena:** Catálogo central de metadatos gobernado y motor de consultas SQL.

Diagrama del Flujo de Orquestación y Control

AWS Step Function gobierna el ciclo de vida de los datos asegurando resiliencia operativa, ejecuta secuencialmente los jobs *Raw-to-Silver* y *Silver-to-Gold* de una manera controla y segura validando los recursos antes de la ejecución:

2. Estimación de Costo Mensual y Proyección de Escala

El modelo *Pay-as-you-go* de AWS asegura que no existan costos fijos de servidores. La siguiente estimación contrasta la operación nominal inicial frente a un escenario de alta demanda (10x volumen de datos, ingestas intradía y mayor número de analistas).



Servicio AWS	Métrica de Escala Considerada	Costo Base	Costo Escalado
Amazon S3	De 50 GB a **500 GB** + 100K peticiones PUT/GET.	$ 1.15	$ 11.50
AWS Lambda	De 30 a **180 validaciones** mensuales (<10s, 256 MB).	$ 0.00	$ 0.00
AWS Glue (Python)	De 30 a **180 jobs/mes** (cargas intradía, 5-10 min/job).	$ 0.28	$ 1.68
Step Functions	De 250 a **1,500 transiciones** (sigue en Free Tier <4K).	$ 0.00	$ 0.00
EventBridge / SNS	Incremento en eventos y alertas por correo.	$ 0.00	$ 0.00
AWS Lake Formation	Escaneo y gobierno de datos (50 GB a 500 GB).	$ 0.11	$ 1.10
Amazon Athena	De 1 TB a **1.5 TB** escaneados en queries analíticos.	$ 5.08	$ 7.50
	Subtotal Infraestructura (Data Lake):	**$ 6.62**	**$ 21.78**
QuickSight (BI)	De 1 Autor / 3 Lectores a **2 Autores** / **10 Lectores**.	$ 27.00	$ 98.00
	Costo Total Estimado Mensual:	**$ 33.62**	**$ 119.78**
	Margen Disponible del Presupuesto ($ 200.00 USD):	*83.1 % ($ 166.38)*	*40.1 % ($ 80.22)*

3. Plan de Implementación por Fases

Proponemos un despliegue iterativo distribuido en 6 semanas.

- **Fase 1: Implementación de almacenamiento (Semanas 1-2)**
  - Despliegue de infraestructura base mediante Infraestructura como Código (CloudFormation).
  - Creación de buckets S3 y funciones de validación (Lambda).
  - *Entregable:* Datos de POS y Shopify aterrizando en S3 *Raw* de forma automatizada.
- **Fase 2: Procesamiento y Modelado (Semanas 3-4)**
  - Programación de los flujos de transformación (Glue) hacia las capas *Silver* y *Gold*.
  - Consolidación de catálogos e historial de ventas.
  - *Entregable:* Tablas analítica consultables en Amazon Athena.
- **Fase 3: Explotación y Automatización (Semanas 5-6)**
  - Activación del orquestador Step Functions para la carga nocturna diaria.
  - Conexión de herramientas de visualización (QuickSight o existente) para los KPIs.
  - *Entregable:* Pipeline operativo 100 % autónomo y dashboards.

4. Supuestos y Preguntas Abiertas

Se establecieron ciertas condiciones y supuestos para la creación del demo propuesto. Las siguientes preguntas tienen como objetivo alinear la propuesta de arquitectura con sus datos reales. Favor de tomarlas en cuenta:

1. **Ventana de Carga:** ¿A qué hora se garantiza que todos los sistemas (POS de tiendas, e-commerce, ERP) han emitido su corte diario para que el data lake inicie su proceso sin riesgo de omitir datos?
2. **Datos Históricos:** Actualmente los flujos están preparados para datos incrementales diarios. ¿Cuántos años de datos históricos necesitan ser migrados inicialmente?
3. **Actualización de Catálogos:** Los catálogos (Tiendas, Productos) fueron tratados como estáticos durante el prototipo. ¿Con qué frecuencia real cambian y qué sistema se considerará la fuente para estos datos?
4. **Visualización y Consumo:** ¿La empresa ya cuenta con herramientas de Business Intelligence (ej. Power BI, Tableau), o requerirán la activación dentro de Amazon QuickSight?

Alejandro Victoria Peregrino
Ingeniero de Datos